

## [연습세트01·블루] 2과목 — 데이터분석

시험 종류: 연습 (정답·해설 공개) | 등급: 블루 | 제한시간: 40분 | 배점: 100점 (단답 90점 + 제출파일 10점)

사용 도구: Python 필수 (pandas · sklearn · matplotlib 등 자유 활용)

### 시나리오

당신은 행정안전부 청렴감사관실 소속 담당자입니다. 기관별 청렴지수 현황 데이터와 부패신고 현황 데이터를 병합·전처리한 뒤, 머신러닝 모델을 구축하여 기관의 부패위험 여부를 예측하는 분석 업무를 맡았습니다.

### 첨부 파일 안내

| 파일명            | 행 수  | 주요 컬럼                                |
|----------------|------|--------------------------------------|
| 첨부/청렴지수_현황.csv | 200행 | 기관코드, 기관명, 기관유형, 지역, 청렴지수, 응답률, 설문인원 |
| 첨부/부패신고_현황.csv | 175행 | 기관코드, 신고건수, 처리완료건수, 처리율, 평균처리일수      |

두 파일에는 결측치와 이상치가 포함되어 있습니다. 분석 전 반드시 처리해주세요.

### 문제 (90점, 부분점수 가능)

데이터 처리 규칙 (정답 산출의 기준입니다)

- 두 CSV를 **기관코드** 키로 inner merge 해주세요.
- 결측치 처리: `dropna()` 로 결측값 행을 제거해주세요.
- 이상치 처리: **설문인원** 과 **평균처리일수** 컬럼에 대해 IQR 방식 ( $Q1 - 1.5 \times IQR$  미만 또는  $Q3 + 1.5 \times IQR$  초과)으로 이상치 행을 제거해주세요.
- 라벨: **부패위험** 은 아래 수식과 시드 251을 사용해 응시자가 직접 생성합니다 (정제 완료 데이터 순서 그대로 적용).

```
import numpy as np

rng = np.random.default_rng(251)
risk = (-0.45 * 청렴지수 + 0.08 * 신고건수
        - 0.012 * 처리율 + 0.04 * 평균처리일수)
risk_n = (risk - risk.mean()) / risk.std() # 표준화
noise = rng.normal(0, 0.5, len(정제데이터))
부패위험 = ((risk_n + noise) > 0.1).astype(int) # 0 또는 1
```

| 문항 | 배점 | 질문                                                 | 답 형식              |
|----|----|----------------------------------------------------|-------------------|
| 1  | 5  | 두 파일을 병합할 때 기준이 되는 공통 컬럼의 이름은 무엇입니까?               | 한글/영문<br>(정확히 일치) |
| 2  | 15 | 전처리 완료 데이터에서 기관유형별 평균 청렴지수가 가장 높은 기관유형의 이름은 무엇입니까? | 한글 (정확히<br>일치)    |

| 문항 | 배점 | 질문                                                                                                   | 답 형식        |
|----|----|------------------------------------------------------------------------------------------------------|-------------|
| 3  | 20 | 결측치 제거 + IQR 이상치 제거 후 남은 데이터의 행 수는 몇 행입니까?                                                           | 정수 (정확히 일치) |
| 4  | 20 | 정제된 데이터에서 라벨이 <b>1 (부패위험)</b> 인 기관의 <b>청렴지수</b> 평균을 반올림한 정수는?                                        | 정수 (정확히 일치) |
| 5  | 30 | 정제된 데이터에 학습/테스트 분할 (test_size=0.2, random_state=42, stratify=라벨)을 적용한 뒤, 테스트셋에서 라벨이 1인 행의 수는 몇 행입니까? | 정수 (정확히 일치) |

#### 응시자 주의사항

- 데이터 정제 순서(merge → dropna → IQR → 라벨 생성)를 안내된 그대로 지켜주세요.
- 라벨 생성 수식과 시드(251)를 그대로 사용해야 문항 4·5의 정답이 재현됩니다.
- 문항 5의 분할 파라미터(test\_size=0.2, random\_state=42, stratify=라벨)는 한 글자도 바꾸지 마세요.
- 모든 문항은 정수 또는 한글 단답으로 정확히 일치해야 정답으로 인정됩니다.

## 제출파일 (10점)

Python으로 분석한 결과를 분석 보고서로 작성하여 제출합니다.

| 파일명                       | 형식                           |
|---------------------------|------------------------------|
| 분석_보고서.docx 또는 분석_보고서.hwp | Microsoft Word 또는 한글(HWP) 문서 |

필수 포함 차트 5종 (Python 차트를 이미지로 캡처하거나 저장하여 보고서에 삽입)

|    |                                           |
|----|-------------------------------------------|
| 1. | 기관유형별 청렴지수 분포 (boxplot)                   |
| 2. | 청렴지수 히스토그램                                |
| 3. | 신고건수 vs 처리율 산점도 (scatter)                 |
| 4. | 4개 알고리즘 F1 비교 막대그래프 (bar)                 |
| 5. | DecisionTree max_depth별 F1 변화 선그래프 (line) |

파일명: 분석\_보고서.docx 또는 분석\_보고서.hwp | 배점: 10점

- Microsoft Word(.docx) 또는 한글(.hwp/.hwp) 문서로 작성
- Python 분석 결과(차트·표·수치)를 보고서에 직접 기술 또는 이미지로 삽입

## 차트 이미지 저장 방법 예시

```
import matplotlib.pyplot as plt
```

```
fig, ax = plt.subplots()
```

```
clean.boxplot(column="청렴지수", by="기관유형", ax=ax)
```

```
fig.savefig("boxplot.png", bbox_inches="tight") # 저장 후 Word/HWP에 삽입
```