

[연습세트02·블루] 2과목 — 데이터분석 (연습)

시험 종류: 연습 (정답·해설 공개) / 등급: 블루 / 제한시간: 40분

배점: 100점 (단답 90 + 제출파일 10)

사용 도구: Python (pandas · sklearn) + AI 보조

시나리오

당신은 행정안전부 자치분권과 데이터 담당자입니다. 2026년 지방자치단체 협력사업 데이터를 머신러닝 관점에서 분석해 **시민참여수가 높은 우수사업(라벨 1)**을 예측하기 위한 기초 데이터를 만듭니다.

분석 유형: 이진분류 · 라벨 = $\text{시민참여수} \geq \text{중앙값} \rightarrow 1(\text{우수사업}), \text{미만} \rightarrow 0$

첨부 안내

- 첨부/자치행정사업.csv (250행) — 사업번호·시도코드·사업분야·총사업비_억원·시민참여수·완료여부
- 첨부/자치단체_마스터.csv (17행) — 시도코드·시도명·재정자립도_퍼센트

문제 (90점, 부분점수 가능)

문 항	배 점	질문	답 형 식
1	15	두 CSV를 머지할 때 사용하는 공통 컬럼명 은 무엇입니까?	한글 단답
2	20	Merge 직후(전처리 전) 시도명별 총사업비 평균 이 가장 높은 시도명은?	한글 단답
3	15	결측치(둘 다 결측 행 제거, 한쪽 결측은 평균 대체)와 이상치(총사업비_억원 > 200 제거)를 처리한 후 남은 행 수 는?	정수
4	20	전처리 후 데이터에서 라벨 1(시민참여수 ≥ 중앙값) 행의 총사업비_억원 평균 은? (반올림 정수)	정수
5	20	전처리 후 데이터를 <code>train_test_split(test_size=0.2, random_state=42, stratify=라벨)</code> 로 분할했을 때 테스트셋의 라벨 1 행 수 는?	정수

머지: `pd.merge(on="공통컬럼", how="inner")` . 시도코드는 2자리 문자열로 통일(`zfill(2)`)해주세요.

제출파일 (10점)

파일명	내용
지 표 .csv	전처리 후 데이터에서 시도명별 라벨1 비율을 정리한 표

- 헤더 1행: 시도명, 사업수, 라벨1수, 라벨1비율
- 데이터 17행 (시도당 1행, 사업수=0이면 라벨1수·비율은 0)
- 정렬: 라벨1비율 내림차순
- 인코딩: UTF-8 (엑셀에서 한글 안 깨지도록 저장)