

[연습세트05·블루] 2과목 — 데이터분석 (연습)

시험 종류: 연습 (정답·해설 공개) / 등급: 블루 / 제한시간: 40분

배점: 100점 (단답 90 + 제출파일 10)

사용 도구: Python (pandas + scikit-learn) + ChatGPT/Claude/Gemini 자유

시나리오

당신은 행정안전부 안전관리과 담당자입니다. 「2026 행정안전부 안전점검 보고서」 부록을 위해 **승강기 중대 고장 샘플 3,000건**과 **시도별 고장지표 마스터**를 결합하여, 고장 연도가 **2020년 이상인지 여부(=최근 고장)**를 이진 분류하는 머신러닝 모델 4종을 비교하세요.

첨부 파일 안내

- 승강기_중대한고장_샘플.csv** — UTF-8, 3,000행, 4컬럼
컬럼: **고장발생일**, **건물명**, **주소**, **승강기고유번호**
- 시도_고장지표.csv** — UTF-8, 시도별 마스터
컬럼: **시도**, **전체_고장수**, **시군구_다양성**, **평균_건물명길이**

데이터 전처리 규칙 (정답 산출 기준 — 아래 순서를 그대로 따르세요)

단계	처리 내용
1 주소 분리	주소 컬럼을 공백(스페이스)으로 나눕니다. · 첫 번째 토큰 → 시도 컬럼 · 두 번째 토큰 → 시군구 컬럼 예) "경기도 양주시 화합로1426번길 39" → 시도 = 경기도, 시군구 = 양주시
2 라벨 생성	고장발생일 의 앞 4글자를 정수 연도로 변환합니다. (예: "2025-07-30" → 2025) 연도가 2020 이상 이면 최근_여부 = 1 , 2020 미만 이면 최근_여부 = 0 으로 정의합니다.
3 두 표 결합	승강기_중대한고장_샘플 (메인)과 시도_고장지표 (마스터)를 시도 컬럼을 키로 inner join(내부 결합) 합니다. 양쪽에 모두 존재하는 시도 만 결과에 남깁니다.

문제 (90점, 부분점수 가능)

문 항	배 점	질문	답 형식
1	15	3단계에서 두 표를 inner join 할 때 사용한 키 컬럼명 은 무엇입니까?	한글 단 답

문 항	배 점	질문	답 형식
			(정확 히 일 치)
2	15	전처리(결측·매칭 정제)를 마친 뒤, inner join 결과의 행 수 는 몇 행입니까?	정수 (정확 히 일 치)
3	20	한 시도의 행 수가 30건 이상 인 시도 중, 최근 고장 비율 (최근_여부=1 비율)이 가장 높은 시도의 이름은?	한글 단 답 (정확 히 일 치)
4	20	정제된 데이터에서 최근_여부 = 1 (최근 고장)인 행의 건물명 글자 수 평균을 반올림 한 정 수는?	정수 (정확 히 일 치)
5	20	정제된 데이터에 <code>train_test_split(test_size=0.2, random_state=42, stratify=최근_여부)</code> 를 적용한 뒤, 테스트셋 에서 최근_여부 = 1 인 행의 수는 몇 행입니까?	정수 (정확 히 일 치)

응시자 주의사항

- 전처리 순서(1 → 2 → 3)를 안내된 그대로 지켜주세요.
- 문항 5의 분할 파라미터 `test_size=0.2, random_state=42, stratify=최근_여부` 는 한 글자도 바꾸지 말고 그대로 사용해주세요. (stratify 기준은 라벨 컬럼 **최근_여부**)
- 모든 문항은 정수 또는 한글 단답으로 **정확히 일치**해야 정답으로 인정됩니다.

제출파일 (10점) — 아래 3종 일괄 제출

1) 차트 2장 (png)

- 시도별 최근 고장 비율 (가로 막대)
- 4개 모델 F1(macro) 비교 (가로 막대)

2) 4개 모델 F1 비교표 (예시 값)

알고리즘	F1(macro)
RandomForest	0.47
LogisticRegression	0.44

알고리즘	F1(macro)
LinearSVC	0.44
GradientBoosting	0.44

3) 결론 5~7줄 + 사용 AI 도구 1줄